

邓鑫

🏠 xin01010.github.io · ✉ dengxin0101@163.com · ☎ +86 133 8894 0572



教育经历

北京航空航天大学

导师：金天 | 研究方向：卫星导航软件接收机高性能实现

硕士 | 信息与通信工程

2024.09 -- 2027.06

吉林大学

GPA: 3.43/4.0 (前 36%)

本科 | 电子信息科学与技术

2020.09 -- 2024.06

科研项目经历

卫星导航装备数字模型

项目负责人, 主要完成人

实验室横向项目

2025.07 -- 2026.01

- 项目简介:** 搭建复杂干扰场景下卫星导航接收机实时定位效果的仿真平台, 开发覆盖抗干扰、卫星导航信息提取与解算的接收机数字模型, 开展 GPU 并行化与实时处理优化。
- 承担工作:** 负责需求拆解、甲方技术对接、代码方案设计及测试验收; 采用 CUDA 完成矩阵计算优化、多通道多支路并发及相关计算的归约优化。针对空时自适应处理 (STAP) 算法在固定并行策略下 GPU 执行效率低的问题, 设计随计算规模调整线程协作范围与数据分块方式的 GPU 优化策略, 减少同步开销、提高片上数据复用, 并完成数值正确性验证、性能测试与瓶颈分析。
- 项目成果:** 完成系统交付, GPU 加速后的 GNSS 软件接收机相较原 CPU 实现获得 $5.32\times$ 整体加速, 完成实时化技术指标; 进一步优化 STAP 抗干扰模块, 在所测配置下相较 GPU 基线加速 $1.36\text{--}2.03\times$ 。围绕 STAP 算法的 GPU 优化开展研究, 形成第一作者 EI 会议论文 1 篇, 已获 AIPIP'2026 接收 (Accepted)。

FlashAttention CUDA 复现与分析 | [GitHub](#)

个人学习项目

- 项目简介:** 基于 FlashAttention v1/v2 论文, 对 FP32 因果注意力前向计算进行 CUDA 复现, 研究分块在线 softmax、循环重排与序列维并行对运行时间、显存需求和 GPU 并行效率的影响。
- 承担工作:** 实现 Standard Attention、FA v1、FA v2 循环重排及序列维并行四种对照方案; 建立 CPU reference 正确性验证与 CUDA-event 计时流程, 完成运行时间、显存增长及固定总 token 数的吞吐量实验。
- 项目成果:** 1.运行时间: 在 RTX 5060 Laptop GPU 所测配置下, FA v1 相对手写 Standard Attention 基线获得约 $1.36\text{--}1.46\times$ 加速; 2.显存需求: 固定 Batch、注意力头数及头维度时, Standard Attention 显存占用随序列长度呈二次增长, FA v1 呈线性增长; 3.GPU 并行效率: 固定总 token 数时, 两种 FA v2 CUDA 实现呈现性能交叉, 循环重排版在短序列领先, 序列维并行版在长序列反超。

实习经历

字节跳动

暑期实习生

ML Infra | 搜广推模型训练

2026.04 -- 2026.08

- 工作职责:** 面向 TikTok Live 搜广推模型, 开展分布式训练性能优化与稳定性排查。结合训练框架中的样本处理流水线、Embedding 访问与参数更新过程, 通过队列状态、算子耗时及 GPU Timeline 定位数据供给、通信与计算瓶颈; 同时参与模型框架迁移与训练异常排查, 并为训练样本预处理模块开发本地 Profiling 功能。
- 工作成果:** 针对多个模型的训练性能瓶颈完成定位与优化, 不同任务的训练吞吐提升约 10%–30%; 通过性能分析定位通信同步导致的 GPU 执行空泡, 启用框架的异步 AllReduce 配置后, 所分析任务中的空泡消失; 交付样本预处理性能分析功能, 支持逐算子执行耗时与算子间样本队列积压情况的统计, 并生成诊断报告, 用于快速定位样本处理链路中的性能瓶颈。

论文成果

- [AIPIP 2026]**Xin Deng**, Tian Jin, and James Chakwizira. “Dimension-Aware GPU Acceleration of Space-Time Adaptive Processing for GNSS Anti-Jamming Software Receivers.” 2026 International Conference on Aerospace Information Perception and Intelligent Processing. [Accepted]